



上海大学
SHANGHAI UNIVERSITY

非线性规划

主要内容

- 基本概念
- 凸函数
- 线性搜索算法
- 无约束极值问题
- 约束极值问题

约束优化问题的最优性条件

$$\begin{cases} \min & f(x) \\ s.t. & g_i(x) \geq 0, \quad i = 1, 2, \dots, m \text{ --- 不等式约束} \\ & h_j(x) = 0, \quad j = 1, 2, \dots, l \text{ --- 等式约束} \\ & x \in E^n \end{cases}$$

$$S = \left\{ x \left| \begin{array}{ll} g_i(x) \geq 0, & i = 1, 2, \dots, m \\ h_j(x) = 0, & j = 1, 2, \dots, l \end{array} \right. \right\} \text{ --- 可行集或可行域}$$

约束优化问题的最优性条件

定义： 对 $\min_{x \in E^n} f(x)$, 设 $\bar{x} \in E^n$ 是任给一点,
 $d \neq 0$, 若存在 $\delta > 0$, 使得对任意的 $\lambda \in (0, \delta)$,
有 $f(\bar{x} + \lambda d) < f(\bar{x})$, 则称 d 为 $f(x)$ 在点 \bar{x} 处的
下降方向 (descent direction)。

$F_0 = \{d \mid \nabla f(\bar{x})^T d < 0\}$, 称为点 \bar{x} 处的下降方向集。

约束优化问题的最优性条件

定义： 设集合 $S \subset E^n$, $\bar{x} \in S$, d 为非零向量, 若存在数 $\delta > 0$, 使得对任意 $\lambda \in (0, \delta)$, 都有

$$\bar{x} + \lambda d \in S$$

则称 d 为集合 S 在 \bar{x} 的可行方向 (feasible direction)。

$$D = \left\{ d \mid d \neq 0, \bar{x} \in clS, \exists \delta > 0, \forall \lambda \in (0, \delta), \text{有 } \bar{x} + \lambda d \in S \right\}$$


是 \bar{x} 处的可行方向锥。

约束优化问题的最优性条件

例：考虑如下约束优化问题：

$$\min f(x) = x_1 + x_2$$

$$s.t. \quad g(x) = 1 - x_1^2 - x_2^2 \geq 0$$



对于任意内点 x^1 ，可行方向锥 $D = R^2$ 。

对于边界点 $x^2 = (-1, 0)^T$ ，可行方向锥

$$D = \{d \in R^2 \mid d_1 > 0\}.$$

约束优化问题的最优性条件

定理1（几何最优性条件）：考虑问题

$$\min f(x)$$

$$s.t. \quad x \in S$$

设 S 是 E^n 的非空集合， $\bar{x} \in S$ ， $f(x)$ 在 \bar{x} 处可微，若 \bar{x} 是局部最优解，则 $F_0 \cap D = \emptyset$ 。

证明：设存在 $d \in F_0 \cap D$ ，则 $d \in F_0, d \in D$ 。

$\because d \in F_0, \therefore \exists \delta_1 > 0$ ，对 $\forall \lambda \in (0, \delta_1)$ ，有 $f(\bar{x} + \lambda d) < f(\bar{x})$ ；

$\because d \in D, \therefore \exists \delta_2 > 0$ ，对 $\forall \lambda \in (0, \delta_2)$ ，有 $\bar{x} + \lambda d \in S$ 。

取 $\delta = \min(\delta_1, \delta_2)$ ，则当 $\lambda \in (0, \delta)$ ，有

$\bar{x} + \lambda d \in S$ 且 $f(\bar{x} + \lambda d) < f(\bar{x})$ ，与 \bar{x} 为局部最优解矛盾。

不等式约束优化问题

一阶最优性条件

$$(1) \quad \begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, i = 1, \dots, m. \end{cases}$$

可行域 $S = \{x | g_i(x) \geq 0, i = 1, \dots, m\}$

定义 若问题(1)的一个可行点 \bar{x} (即 $\bar{x} \in S$)使某个不等式约束 $g_i(x) \geq 0$ 变成等式, 即 $g_i(\bar{x}) = 0$, 则该不等式约束称为关于可行点 \bar{x} 的**起作用约束 (或等式约束)**; 否则, 若 \bar{x} 使得某个 $g_i(\bar{x}) > 0$, 则该不等式约束称为关于可行点 \bar{x} 的**不起作用约束 (或松约束)**。

记 $I = \{i | g_i(\bar{x}) = 0, \bar{x} \in S\}$


例：约束

$$\begin{cases} g_1(x) = -x_1^2 - x_2^2 + 1 \geq 0 \\ g_2(x) = x_1 - x_2 \geq 0 \\ g_3(x) = x_1 \geq 0 \\ g_4(x) = x_2 \geq 0 \end{cases}$$

$$x_A = (1, 0)^T, x_B = \left(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2} \right)^T$$

$$G_0 = \left\{ d \mid \nabla g_i(\bar{x})^T d > 0, i \in I \right\}$$

称 G_0 为 S 在点 \bar{x} 处的局部约束方向锥（或内方向锥）。



不等式约束优化问题

$$G_0 = \left\{ d \mid \nabla g_i(\bar{x})^T d > 0, i \in I \right\}$$

称 G_0 为 S 在点 \bar{x} 处的局部约束方向锥（或内方向锥）。

证：对于起作用约束： $g_i(\bar{x})=0$ ；存在 $\delta > 0$ ，
使得任意 $\lambda \in (0, \delta)$ ，有 $g_i(\bar{x}+\lambda d) \geq g_i(\bar{x})=0$ ，

从而 $\lim_{\lambda \rightarrow 0} \frac{g_i(\bar{x}+\lambda d)-g_i(\bar{x})}{\lambda} = \nabla g_i(\bar{x})^T d \geq 0$ 。

由泰勒公式， $g_i(\bar{x}+\lambda d)=g_i(\bar{x})+\lambda \nabla g_i(\bar{x})^T d+o(\lambda)$ ，

当 λ 足够小时，只要 $\nabla g_i(\bar{x})^T d > 0$ ，就有 $g_i(\bar{x}+\lambda d) \geq 0$ 。



定理2: 设 $\bar{x} \in S$, $f(x)$ 和 $g_i(x)(i \in I)$ 在 \bar{x} 处可微, $g_i(x)(i \notin I)$ 在 \bar{x} 处连续, 如果 \bar{x} 是问题(1)的局部最优解, 则 $F_0 \cap G_0 = \emptyset$ 。

证明: 由定理1, 在 \bar{x} 处, 有 $F_0 \cap D = \emptyset$.

设 $d \in G_0$, 则 $\nabla g_i(\bar{x})^T d > 0, i \in I$; 令 $\tilde{g}_i(x) = -g_i(x), i \in I$.

则 $\nabla \tilde{g}_i(\bar{x})^T d < 0, i \in I$;

由引理, 存在 $\delta_1 > 0$, 当 $\lambda \in (0, \delta_1)$ 时, 有 $\tilde{g}_i(\bar{x} + \lambda d) < \tilde{g}_i(\bar{x}), i \in I$

即 $g_i(\bar{x} + \lambda d) > g_i(\bar{x}) = 0, i \in I$.

当 $i \notin I$ 时, $g_i(\bar{x}) > 0, \because g_i(\bar{x})(i \notin I)$ 在 \bar{x} 连续,

\therefore 存在 $\delta_2 > 0$, 当 $\lambda \in (0, \delta_2)$ 时, 有 $g_i(\bar{x} + \lambda d) > 0, i \notin I$.

令 $\delta = \min(\delta_1, \delta_2)$, 则当 $\lambda \in (0, \delta)$ 时, 有 $g_i(\bar{x} + \lambda d) > 0, \forall i$,

$\Rightarrow \bar{x} + \lambda d \in S \Rightarrow d \in D \Rightarrow G_0 \subseteq D \Rightarrow F_0 \cap G_0 = \emptyset$

Farkas 引理： 设 A 为 $m \times n$ 矩阵， c 为 n 维列向量，则
 $Ax \leq 0, c^T x > 0$ 有解的充要条件是 $A^T y = c, y \geq 0$ 无解。

证明：“ \Rightarrow ”（反证法）假设存在 $y \geq 0$ ，使得 $A^T y = c$

$$\text{得 } y^T A = c^T$$

设 \bar{x} 为 $Ax \leq 0, c^T x > 0$ 的一个解，

$$\text{则有 } A\bar{x} \leq 0, c^T \bar{x} > 0$$

$$\Rightarrow y^T A\bar{x} = c^T \bar{x} > 0 \quad (1)$$

$$\because y \geq 0, \text{ 但 } A\bar{x} \leq 0$$

$$\therefore y^T A\bar{x} \leq 0 \text{ 与 (1) 矛盾。}$$



“ \Leftarrow ” 设 $A^T y = c, y \geq 0$ 无解, 令

$$S = \{z \mid z = A^T y, y \geq 0\}, \text{ 则 } c \notin S$$

可以证明 S 为闭凸集, 由点与凸集强可分离定理,

$\exists x \neq 0, \varepsilon > 0$, 使得对 $\forall z \in S$, 有 $x^T c \geq \varepsilon + x^T z$

$$\because \varepsilon > 0, \therefore x^T c > x^T z$$

$$\Rightarrow c^T x > z^T x = y^T Ax$$

即对任意的 $y \geq 0$, 有 $c^T x > y^T Ax$ (1)

令 $y = 0$, 得 $c^T x > 0$

$\because c^T x$ 为一定数, y 的分量可取任意大,

\therefore 由(1), 必有 $Ax \leq 0$.

即非零向量 x 是 $Ax \leq 0, c^T x > 0$ 的解。

不等式约束优化问题

Gordan定理: 设 A 为 $m \times n$ 矩阵, 那么 $Ax < 0$ 有解的充要条件是不存在非零向量 $y \geq 0$, 使得 $A^T y = 0$ 。

证明:

“ \Rightarrow ” 设存在 \bar{x} , 使得 $A\bar{x} < 0$

若存在非零向量 $y \geq 0$, 使得 $A^T y = 0$

则有 $y^T A = 0$, $\Rightarrow y^T A\bar{x} = 0$

$\because A\bar{x} < 0$

$\therefore y$ 的各分量不可能为非负数, 与 $y \geq 0$ 矛盾.

不等式约束优化问题

“ \Leftarrow ”（证等价命题）即若 $Ax < 0$ 无解，则存在非零向量 $y \geq 0$ ，使得 $A^T y = 0$ 。

设 $Ax < 0$ 无解，令 $S_1 = \{z \mid z = Ax, x \in E^n\}$ $S_2 = \{z \mid z < 0\}$

$\because Ax < 0$ 无解， $\therefore S_1 \cap S_2 = \emptyset$ ，由凸集分离定理知，

存在非零向量 y ，使得对 $\forall x \in E^n, \forall z \in S_2$ ，有

$$y^T Ax \geq y^T z \quad (1)$$

特别地，当 $x = 0$ 时，有 $y^T z \leq 0$ 。 $\because z < 0$ ，它的分量可取任意负数， $\therefore y \geq 0$

在（1）中令 $z \rightarrow 0$ ，则对 $\forall x \in E^n$ ，有

$$y^T Ax \geq 0 \quad (2)$$

令 $x = -A^T y$ ，代入（2），得 $-y^T AA^T y \geq 0$ ，即 $-\|A^T y\|^2 \geq 0$ ， $\therefore A^T y = 0$ 。

因此，存在非零向量 $y \geq 0$ ，使得 $A^T y = 0$ 。

不等式约束优化问题

定理3(*Fritz John*条件) 设 $\bar{x} \in S, I = \{i \mid g_i(\bar{x}) = 0\}$,
 $f(x), g_i(x)(i \in I)$ 在 \bar{x} 处可微, $g_i(x)(i \notin I)$ 在 \bar{x} 处
连续, 若 \bar{x} 是问题(1)的局部最优解, 则存在不全为零的数 $w_0, w_i(i \in I)$, 使得

$$\begin{cases} w_0 \nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) = 0 \\ w_0, w_i \geq 0, \quad i \in I. \end{cases}$$

\bar{x} 称为**Fritz John** 点(即满足**Fritz John**条件的点).



不等式约束优化问题

证明：由定理2，在点 \bar{x} , $F_0 \cap G_0 = \emptyset$, 即不等式
$$\begin{cases} \nabla f(\bar{x})^T d < 0 \\ -\nabla g_i(\bar{x})^T d < 0, \quad i \in I \end{cases}$$
 无解。

设 $I = \{i_1, i_2, \dots, i_s\}$, 令 $A = \begin{pmatrix} \nabla f(\bar{x})^T \\ -\nabla g_{i_1}(\bar{x})^T \\ \vdots \\ -\nabla g_{i_s}(\bar{x})^T \end{pmatrix}$

有 $Ad < 0$ 无解, 由 *Gordan* 定理, 存在 $w = (w_0, w_{i_1}, \dots, w_{i_s})^T \geq 0, w \neq 0$, 使得

$$A^T w = 0, \text{ 即 } \left(\nabla f(\bar{x}), -\nabla g_{i_1}(\bar{x}), \dots, -\nabla g_{i_s}(\bar{x}) \right) \begin{pmatrix} w_0 \\ w_{i_1} \\ \vdots \\ w_{i_s} \end{pmatrix} = 0$$

$$\Rightarrow w_0 \nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) = 0.$$

不等式约束优化问题

定理3'(*Fritz John*条件) 设 $\bar{x} \in S, I = \{i \mid g_i(\bar{x}) = 0\}$,
 $f(x), g_i(x)$ 在 \bar{x} 处可微, 若 \bar{x} 是问题(1)的局部最优解, 则存在不全为零的数 w_0, w_1, \dots, w_m , 使得

$$\begin{cases} w_0 \nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) = 0 \\ w_i g_i(\bar{x}) = 0, \quad i = 1, 2, \dots, m \\ w_0, w_i \geq 0, \quad i = 1, 2, \dots, m. \end{cases}$$

互补松弛条件

不等式约束优化问题

问题

$$\begin{cases} \min & f(x) \\ s.t. & g_i(x) \leq \mathbf{0}, i = 1, 2, \dots, m \end{cases}$$

的 *Fritz John* 条件为

$$\begin{cases} w_0 \nabla f(\bar{x}) + \sum_{i \in I} w_i \nabla g_i(\bar{x}) = \mathbf{0} \\ w_0, w_i \geq \mathbf{0}, \quad i \in I. \end{cases}$$

不等式约束优化问题

例：设非线性规划问题

$$\left\{ \begin{array}{l} \min f(x) = (x_1 - 3)^2 + (x_2 - 2)^2 \\ s.t. \quad g_1(x) = -x_1^2 - x_2^2 + 5 \geq 0 \\ \quad \quad g_2(x) = -x_1 - 2x_2 + 4 \geq 0 \\ \quad \quad g_3(x) = x_1 \geq 0 \\ \quad \quad g_4(x) = x_2 \geq 0 \end{array} \right. \quad \left\{ \begin{array}{l} w_0 \nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) = 0 \\ w_i g_i(\bar{x}) = 0, \quad i = 1, 2, \dots, m \\ w_0, w_i \geq 0, \quad i = 1, 2, \dots, m. \end{array} \right.$$

判别点 $x^{(1)} = (2, 1)^T$ 和 $x^{(2)} = (0, 0)^T$ 是否是 *Fritz John* 点？

解： $\nabla f(x) = (2(x_1 - 3), 2(x_2 - 2))^T$


$$\nabla g_1(x) = (-2x_1, -2x_2)^T, \quad \nabla g_2(x) = (-1, -2)^T$$

$$\nabla g_3(x) = (1, 0)^T, \quad \nabla g_4(x) = (0, 1)^T$$

不等式约束优化问题

例2. 设非线性规划问题：

$$\begin{cases} \min -x_1 \\ s.t. \quad g_1(x) = -x_2 + (1-x_1)^3 \geq 0 \\ \quad \quad g_2(x) = x_2 \geq 0 \end{cases}$$



判别点 $x^{(1)} = (1, 0)^T$ 是否是 *Fritz John* 点？

解： $\because \nabla f(x) = (-1, 0)^T$, $\nabla g_1(x) = (-3(1-x_1)^2, -1)^T$, $\nabla g_2(x) = (0, 1)^T$
在点 $x^{(1)} = (1, 0)^T$ 处, $I = \{1, 2\}$, $\nabla f(x^{(1)}) = (-1, 0)^T$, $\nabla g_1(x^{(1)}) = (0, -1)^T$,

$$\nabla g_2(x) = (0, 1)^T, \text{ 设有 } w_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} - w_1 \begin{pmatrix} 0 \\ -1 \end{pmatrix} - w_2 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = 0$$

$\Rightarrow w_0 = 0$, 取 $w_1 = w_2 > 0 \Rightarrow x^{(1)} = (1, 0)^T$ 是 *Fritz John* 点。

不等式约束优化问题

例: $\min f(x) = (x_1 - 1)^2 + (x_2 - 1)^2$

$s.t. \quad g_1(x) = (1 - x_1 - x_2)^3 \geq 0$

$g_2(x) = x_1 \geq 0$

$g_3(x) = x_2 \geq 0$

最优解为

$$x^* = \left(\frac{1}{2}, \frac{1}{2} \right)^T.$$

\therefore 直线 $x_1 + x_2 = 1$ 上所有可行点 \bar{x} 使 $\nabla g_1(\bar{x}) = 0$,

\therefore 取 $w_0 = 0, w_1 = a > 0, w_2 = w_3 = 0$, 总有

$$w_0 \nabla f(\bar{x}) - w_1 \nabla g_1(\bar{x}) - w_2 \nabla g_2(\bar{x}) - w_3 \nabla g_3(\bar{x}) = 0$$

说明在直线 $x_1 + x_2 = 1$ 上每个可行点 \bar{x} 都是 *Fritz John* 点, 但除 x^* 外, 都不是最优解。

不等式约束优化问题

定理2. 考虑问题
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \end{cases}$$

设 $\bar{x} \in S$, $f, g_i (i \in I)$ 在 \bar{x} 处可微, $g_i (i \notin I)$ 在 \bar{x} 连续, $\{\nabla g_i(\bar{x}) | i \in I\}$ 线性无关, 若 \bar{x} 是局部最优解, 则存在非负数 $w_i, i \in I$, 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) = 0.$$

不等式约束优化问题

证明：由定理1，存在不全为零的非负数

$w_0, w'_i, i \in I$ ，使得

$$w_0 \nabla f(\bar{x}) - \sum_{i \in I} w'_i \nabla g_i(\bar{x}) = 0.$$

显然 $w_0 \neq 0$ ，否则 $\nabla g_i(\bar{x}) (i \in I)$ 线性相关，矛盾。

于是，令 $w_i = \frac{w'_i}{w_0} \geq 0 (i \in I)$ ，得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) = 0.$$

不等式约束优化问题

- Karush-Kuhn-Tucker(KKT或KT)条件

定理2'. 考虑问题
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \end{cases}$$

设 $\bar{x} \in S$, f, g_i 在 \bar{x} 可微, $\{\nabla g_i(\bar{x}) | i \in I\}$ 线性无关,

若 \bar{x} 是局部最优解, 则存在数 $w_i, i = 1, 2, \dots, m$, 使得

$$\nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) = 0$$

$$w_i g_i(\bar{x}) = 0 \quad i = 1, 2, \dots, m$$

$$w_i \geq 0 \quad i = 1, 2, \dots, m.$$

互补松弛条件

不等式约束优化问题

例：给定非线性规划问题

$$\begin{cases} \min f(x) = (x_1 - 1)^2 + x_2 \\ s.t. \quad g_1(x) = -x_1 - x_2 + 2 \geq 0 \\ \quad \quad g_2(x) = x_2 \geq 0 \end{cases}$$

求满足 KKT 条件的点。

解： $\nabla f(x) = (2(x_1 - 1), 1)^T$, $\nabla g_1(x) = (-1, -1)^T$, $\nabla g_2(x) = (0, 1)^T$

设 x 为满足 KKT 条件的点，则有

$$\begin{cases} \begin{pmatrix} 2(x_1 - 1) \\ 1 \end{pmatrix} - w_1 \begin{pmatrix} -1 \\ -1 \end{pmatrix} - w_2 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ w_1(-x_1 - x_2 + 2) = 0 \\ w_2 x_2 = 0, \quad -x_1 - x_2 + 2 \geq 0 \\ w_1, w_2 \geq 0, \quad x_2 \geq 0 \end{cases}$$

$$\begin{cases} \nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) = 0 \\ w_i g_i(\bar{x}) = 0, \quad i = 1, 2, \dots, m \\ w_i \geq 0, \quad i = 1, 2, \dots, m. \end{cases}$$

$1/7/2025 \Rightarrow x_1 = 1, x_2 = 0, w_1 = 0, w_2 = 1$, 即 KKT 点为 $(1, 0)^T$.

不等式约束优化问题

例:求下列非线性规划问题的**KKT**点.

$$\min f(x) = 2x_1^2 + 2x_1x_2 + x_2^2 - 10x_1 - 10x_2$$

$$s.t. \quad g_1(x) = -x_1^2 - x_2^2 + 5 \geq 0$$

$$g_2(x) = -3x_1 - x_2 + 6 \geq 0$$

$$\nabla f(x) = \begin{pmatrix} 4x_1 + 2x_2 - 10 \\ 2x_1 + 2x_2 - 10 \end{pmatrix}$$

$$\nabla g_1(x) = \begin{pmatrix} -2x_1 \\ -2x_2 \end{pmatrix} \quad \nabla g_2(x) = \begin{pmatrix} -3 \\ -1 \end{pmatrix}$$

不等式约束优化问题

设 x 为满足 KKT 条件的点，则有

$$\left\{ \begin{array}{l} 4x_1 + 2x_2 - 10 + 2w_1x_1 + 3w_2 = 0 \\ 2x_1 + 2x_2 - 10 + 2w_1x_2 + w_2 = 0 \\ w_1(-x_1^2 - x_2^2 + 5) = 0 \\ w_2(-3x_1 - x_2 + 6) = 0 \\ -x_1^2 - x_2^2 + 5 \geq 0 \\ -3x_1 - x_2 + 6 \geq 0 \\ w_1, w_2 \geq 0 \end{array} \right.$$

凸规划

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, 2, \dots, l. \end{cases}$$

其中是 $f(x)$ 凸函数, $g_i(x)$ 是凹函数,
 $h_j(x)$ 是线性函数。

凸规划

定理3.(一阶充分条件)

$$\text{设问题} \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \end{cases}$$

中, f 是凸函数, $g_i (i = 1, 2, \dots, m)$ 是凹函数, S 为可行域, $\bar{x} \in S$, $I = \{i \mid g_i(\bar{x}) = 0\}$. f 和 $g_i (i \in I)$ 在点 \bar{x} 可微, $g_i (i \notin I)$ 在点 \bar{x} 连续, 且在 \bar{x} 处 KKT 条件成立, 则 \bar{x} 为整体极小点。

凸规划

证明：显然 S 为凸集，

$\because \bar{x} \in S, f$ 为凸函数且在 \bar{x} 可微, \therefore 对 $\forall x \in S$

$$f(x) \geq f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) \text{---(1)}$$

又点 \bar{x} 处 KKT 条件成立, 所以存在 $w_i (i \in I), w_i \geq 0$

使得 $\nabla f(\bar{x}) = \sum_{i \in I} w_i \nabla g_i(\bar{x}) \text{---(2)}$

代入(1)得 $f(x) \geq f(\bar{x}) + \sum_{i \in I} w_i \nabla g_i(\bar{x})^T (x - \bar{x}) \text{---(3)}$

$\because g_i$ 是凹函数, \therefore 当 $i \in I$ 有

$$g_i(x) \leq g_i(\bar{x}) + \nabla g_i(\bar{x})^T (x - \bar{x})$$

$$\Rightarrow \nabla g_i(\bar{x})^T (x - \bar{x}) \geq g_i(x) - g_i(\bar{x}) = g_i(x) \geq 0 \text{---(4)}$$

将(4)代入(3), 得 $f(x) \geq f(\bar{x}) \Rightarrow \bar{x}$ 是整体最优解.

一般约束问题

$$(NP) \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

$$\begin{cases} \min f(x) \\ s.t. \quad g(x) \geq 0 \\ \quad \quad h(x) = 0 \end{cases} \quad g(x) = \begin{bmatrix} g_1(x) \\ g_2(x) \\ \vdots \\ g_m(x) \end{bmatrix}, h(x) = \begin{bmatrix} h_1(x) \\ h_2(x) \\ \vdots \\ h_l(x) \end{bmatrix}$$

一般约束问题

定理1(*Fritz John*条件) 设 $\bar{x} \in S, I = \{i \mid g_i(\bar{x}) = 0\}$,
 $f(x), g_i(x)(i \in I)$ 在 \bar{x} 处可微, $g_i(x)(i \notin I)$ 在 \bar{x} 处
连续, $h_j(j = 1, 2, \dots, l)$ 在 \bar{x} 处连续可微, 若 \bar{x} 是问
题(*NP*)的局部最优解, 则存在不全为零的数 w_0 ,
 $w_i(i \in I)$ 和 $v_j(j = 1, 2, \dots, l)$, 使得

$$\begin{cases} w_0 \nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0 \\ w_0, w_i \geq 0, \quad i \in I. \end{cases}$$

$$h_i(x)=0 \rightarrow \begin{cases} h_i(x) \geq 0 \\ -h_i(x) \geq 0 \end{cases}$$

一般约束问题

定理1' (*Fritz John*条件) 设 $\bar{x} \in S$, $I = \{i \mid g_i(\bar{x}) = 0\}$, $f(x), g_i(x)$ 在 \bar{x} 处可微, $h_j (j = 1, 2, \dots, l)$ 在 \bar{x} 处连续可微, 若 \bar{x} 是问题 (*NP*) 的局部最优解, 则存在不全为零的数 $w_0, w_i (i \in I)$ 和 $v_j (j = 1, 2, \dots, l)$, 使得

$$\left\{ \begin{array}{l} w_0 \nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0 \\ w_i g_i(\bar{x}) = 0, \quad i = 1, 2, \dots, m \\ w_0, w_i \geq 0, \quad i = 1, 2, \dots, m. \end{array} \right.$$

一般约束问题

定理2(KKT必要条件) 考虑问题
$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. $f, g_i (i \in I)$ 在 \bar{x} 处可微,
 $g_i (i \notin I)$ 在 \bar{x} 连续, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 \bar{x} 是局部最优解, 则存在数 $w_i, i \in I$
和 $v_j (j = 1, \dots, l)$, 使得

$$\nabla f(\bar{x}) - \sum_{i \in I} w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0.$$

$$w_i \geq 0 \quad (i \in I).$$

一般约束问题

定理2'(KKT必要条件) 考虑问题

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. f, g_i 在 \bar{x} 处可微, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集 $\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$ 线性无关, 若 \bar{x} 是局部最优解, 则存在数 $w_i, i \in I$ 和 $v_j (j = 1, \dots, l)$, 使得

$$\nabla f(\bar{x}) - \sum_{i=1}^m w_i \nabla g_i(\bar{x}) - \sum_{j=1}^l v_j \nabla h_j(\bar{x}) = 0$$

$$w_i g_i(\bar{x}) = 0, i = 1, 2, \dots, m$$

$$w_i \geq 0 \quad i = 1, 2, \dots, m.$$

一般约束问题

定义广义的**Lagrange**函数:

$$\begin{aligned} L(x, w, v) &= f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \\ &= f(x) - w^T g(x) - v^T h(x) \end{aligned}$$

其中 $w = (w_1, w_2, \dots, w_m)^T$

$v = (v_1, v_2, \dots, v_l)^T$

$g(x) = (g_1(x), \dots, g_m(x))^T$

$h(x) = (h_1(x), \dots, h_l(x))^T$.



乘子向量

一般约束问题

定理2'(KKT必要条件) 考虑问题
$$\begin{cases} \min f(x) \\ \text{s.t.} \quad g_i(x) \geq 0, i = 1, \dots, m \\ \quad \quad h_j(x) = 0, j = 1, \dots, l \end{cases}$$

设 \bar{x} 为可行点, $I = \{i \mid g_i(\bar{x}) = 0\}$. f, g_i 在 \bar{x} 处可微, $h_j (j = 1, \dots, l)$ 在 \bar{x} 连续可微, 向量集

$$\{\nabla g_i(\bar{x}), \nabla h_j(\bar{x}) \mid i \in I, j = 1, \dots, l\}$$

线性无关, 若 \bar{x} 是局部最优解, 则存在乘子向量 $\bar{w} \geq 0, \bar{v}$, 使得

$$\nabla_x L(\bar{x}, \bar{w}, \bar{v}) = 0$$

一般约束问题

一般情形的一阶必要条件(**KKT**必要条件)可表示为:

$$\left\{ \begin{array}{l} \nabla_x L(x, w, v) = 0 \\ w_i g_i(x) = 0, i = 1, 2, \dots, m \\ g_i(x) \geq 0, i = 1, 2, \dots, m \\ h_j(x) = 0, j = 1, 2, \dots, l \\ w_i \geq 0, i = 1, 2, \dots, m \end{array} \right.$$

一般约束问题-凸规划

定理3.(一阶充分条件)

$$\text{设问题} \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

中, f 是凸函数, $g_i (i = 1, 2, \dots, m)$ 是凹函数,
 $h_j (j = 1, 2, \dots, l)$ 是线性函数, S 为可行域,
 $\bar{x} \in S$, $I = \{i \mid g_i(\bar{x}) = 0\}$. f 和 $g_i (i \in I)$ 在点 \bar{x} 可微,
 $h_j (j = 1, 2, \dots, l)$ 在点 \bar{x} 连续, $g_i (i \notin I)$ 在点 \bar{x} 连续,
且在 \bar{x} 处 KKT 条件成立, 则 \bar{x} 为整体极小点。

一般约束问题-凸规划

证明：显然 S 为凸集，

$\because \bar{x} \in S, f$ 为凸函数且在 \bar{x} 可微, \therefore 对 $\forall x \in S$

$$f(x) \geq f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x})$$

而
$$\nabla f(\bar{x}) = \sum_{i \in I} w_i \nabla g_i(\bar{x}) + \sum_{j=1}^l v_j \nabla h_j(\bar{x})$$

$$\therefore f(x) \geq f(\bar{x}) + \sum_{i \in I} w_i \nabla g_i(\bar{x})^T (x - \bar{x}) + \sum_{j=1}^l v_j \nabla h_j(\bar{x})^T (x - \bar{x})$$

$$\because g_i \text{ 是凹函数, } \therefore \text{当 } i \in I \text{ 有 } g_i(x) \leq g_i(\bar{x}) + \nabla g_i(\bar{x})^T (x - \bar{x})$$

$$\Rightarrow \nabla g_i(\bar{x})^T (x - \bar{x}) \geq g_i(x) - g_i(\bar{x}) = g_i(x) \geq 0$$

$$\because h_j \text{ 为线性函数 } \therefore h_j(x) = h_j(\bar{x}) + \nabla h_j(\bar{x})^T (x - \bar{x})$$

$$\Rightarrow \nabla h_j(\bar{x})^T (x - \bar{x}) = 0 \Rightarrow f(x) \geq f(\bar{x}) \Rightarrow \bar{x} \text{ 是整体最优解.}$$

一般约束问题-凸规划

推论1: 设 (NP) 是线性约束的凸规划,
则 $\bar{x} \in S$ 是整体最优解 $\Leftrightarrow \bar{x}$ 是KKT点。

推论2: 问题
$$\begin{cases} \min cx \\ s.t. \quad Ax \geq b, \\ \quad \quad x \geq 0 \end{cases}$$
 则 x^* 是最优解

\Leftrightarrow 存在 $w \in R^m, v \in R^n$, 使得
$$\begin{cases} Ax^* \geq b \\ x^* \geq 0 \\ c - w^T A - v^T = 0 \\ w^T (Ax^* - b) = 0 \\ v^T x^* = 0 \\ w, v \geq 0 \end{cases}$$

一般约束问题-凸规划

求解下列线性规划问题：

$$\left\{ \begin{array}{l} \min -2x_1 + x_2 \\ s.t. \quad x_1 + x_2 + x_3 \geq 4 \\ \quad \quad x_1 + 2x_2 + 2x_3 \leq 6 \\ \quad \quad x_1, x_2, x_3 \geq 0 \end{array} \right.$$



$$\left\{ \begin{array}{l} \min -2x_1 + x_2 \\ s.t. \quad x_1 + x_2 + x_3 - 4 \geq 0 \\ \quad \quad -x_1 - 2x_2 - 2x_3 + 6 \geq 0 \\ \quad \quad x_1, x_2, x_3 \geq 0 \end{array} \right.$$

一般约束问题-凸规划

由**KKT**条件,得

$$\begin{cases}
 -2 - w_1 + w_2 - w_3 = 0 & (1) \\
 1 - w_1 + 2w_2 - w_4 = 0 & (2) \\
 -w_1 + 2w_2 - w_5 = 0 & (3) \\
 w_1(x_1 + x_2 + x_3 - 4) = 0 & (4) \\
 w_2(-x_1 - 2x_2 - 2x_3 + 6) = 0 & (5) \\
 w_3x_1 = 0 \quad w_4x_2 = 0 \quad w_5x_3 = 0 & (6) \\
 w_i \geq 0, x_i \geq 0 & (7) \\
 x_1 + x_2 + x_3 - 4 \geq 0 & (8) \\
 -x_1 - 2x_2 - 2x_3 + 6 \geq 0 & (9)
 \end{cases}
 \begin{cases}
 Ax^* \geq b \\
 x^* \geq 0 \\
 c - w^T A - v^T = 0 \\
 w^T (Ax^* - b) = 0 \\
 v^T x^* = 0 \\
 w, v \geq 0
 \end{cases}$$

得到**KKT**点 $(6, 0, 0)^T$.

$(6, 0, 0)^T$ 为整体最优解。

一般约束问题-凸规划

例：用**KKT**条件解下列问题：

$$\left\{ \begin{array}{l} \min f = (x_1 - 1)^2 + (x_2 - 1)^2 \\ s.t. \quad -x_1 - x_2 + 2 \geq 0 \\ \quad \quad x_2 - x_1 = 1 \\ \quad \quad x_1 \geq 0 \\ \quad \quad x_2 \geq 0 \end{array} \right.$$

$$\nabla f(x) = (2(x_1 - 1), 2(x_2 - 1))^T \quad \nabla g_1(x) = (-1, -1)^T$$

$$\nabla g_2(x) = (1, 0)^T \quad \nabla g_3(x) = (0, 1)^T \quad \nabla h(x) = (-1, 1)^T$$

一般约束问题-凸规划

KKT条件为:

$$\left\{ \begin{array}{l} 2(x_1 - 1) - w_1(-1) - w_2 - v(-1) = 0 \\ 2(x_2 - 2) - w_1(-1) - w_3 - v = 0 \\ -x_1 - x_2 + 2 \geq 0 \\ x_2 - x_1 = 1 \\ x_1, x_2 \geq 0 \\ w_1(-x_1 - x_2 + 2) = 0 \\ w_2 x_1 = 0 \\ w_3 x_2 = 0 \\ w_1, w_2, w_3 \geq 0 \end{array} \right.$$

$$x^* = \left(\frac{1}{2}, \frac{3}{2} \right)^T \text{ 为 } KKT \text{ 点.}$$

因为 $f(x)$ 为凸函数, $g_i(x)$, $h(x)$ 为线性函数, 所以本问题为凸规划问题,
 $\Rightarrow x^*$ 为全局最优解

$$f_{\min} = \frac{1}{2}$$

一般约束问题

例:

$$\begin{aligned} \min f(x) &= x_2 \\ \text{s.t. } g(x) &= x_1^2 + x_2 \geq 0 \end{aligned}$$

KKT点应满足方程组

$$\begin{cases} \begin{pmatrix} 0 \\ 1 \end{pmatrix} - w \begin{pmatrix} 2x_1 \\ 1 \end{pmatrix} = 0 \\ w(x_1^2 + x_2) = 0 \\ x_1^2 + x_2 \geq 0 \\ w \geq 0 \end{cases}$$



$$w = 1$$

$$x_1 = x_2 = 0$$

$x^* = (0, 0)^T$ 不是极小点。

一般约束问题

例:

$$\min x_1^2 - 3x_2 - x_2^2$$

$$s.t. \quad x_2 = 0$$

$$\text{最优解 } x^* = (0, 0)^T$$

Lagrange函数为

$$L(x, v) = x_1^2 - 3x_2 - x_2^2 - vx_2 = x_1^2 - (v + 3)x_2 - x_2^2$$

$$\nabla L(x, v) = \begin{pmatrix} 2x_1 \\ -(v + 3) - 2x_2 \end{pmatrix}, \quad \nabla^2 L(x, v) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$$

注意: **Lagrange**函数的**Hessian**矩阵不定
不能说明该函数有没有极值点。

例：给定非线性规划问题

$$\begin{cases} \min f(x) = (x_1 - 1)^2 + x_2 \\ s.t. \quad g_1(x) = -x_1 - x_2 + 2 \geq 0 \\ \quad \quad g_2(x) = x_2 \geq 0 \end{cases}$$

求满足 KKT 条件的点。

解： $\nabla f(x) = (2(x_1 - 1), 1)^T$, $\nabla g_1(x) = (-1, -1)^T$, $\nabla g_2(x) = (0, 1)^T$

设 x 为满足 KKT 条件的点，则有

$$\begin{cases} \begin{pmatrix} 2(x_1 - 1) \\ 1 \end{pmatrix} - w_1 \begin{pmatrix} -1 \\ -1 \end{pmatrix} - w_2 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ w_1(-x_1 - x_2 + 2) = 0 \\ w_2 x_2 = 0, \quad -x_1 - x_2 + 2 \geq 0 \\ w_1, w_2 \geq 0, \quad x_2 \geq 0 \end{cases}$$

$$\Rightarrow x_1 = 1, x_2 = 0, w_1 = 0, w_2 = 1$$

1/7/2025 即 KKT 点为 $(1, 0)^T$.

一般约束问题

KKT体现一阶信息，当一阶信息不够用，
有必要考虑二阶信息

可行点 \bar{x} 是 **KKT** 点, $(\bar{x}, \bar{w}, \bar{v})$ 满足 **KKT** 条件,

$$\nabla_x L(\bar{x}, \bar{w}, \bar{v}) = 0$$

$$\nabla f(\bar{x}) - \sum_{i \in I} \bar{w}_i \nabla g_i(\bar{x}) - \sum_{j=1}^l \bar{v}_j \nabla h_j(\bar{x}) = 0$$

一般约束问题

定理（二阶充分条件）：设 $f, g_i (i=1, \dots, m)$ 和 $h_j (j=1, \dots, l)$ 是二次连续可微函数， \bar{x} 为可行解，若存在 \bar{w}, \bar{v} ，使 $(\bar{x}, \bar{w}, \bar{v})$ 满足KKT条件且矩阵 $\nabla^2 L_x(\bar{x}, \bar{w}, \bar{v})$ 在子空间 G 上是正定的，则 \bar{x} 是严格局部极小点。

$$\text{其中 } G = \left\{ d \neq 0 \left| \begin{array}{l} \nabla g_i(\bar{x})^T d = 0, i \in I(\bar{x}) \text{ 且 } \bar{w}_i > 0 \\ \nabla g_i(\bar{x})^T d \geq 0, i \in I(\bar{x}) \text{ 且 } \bar{w}_i = 0 \\ \nabla h_j(\bar{x})^T d = 0, j = 1, 2, \dots, l \end{array} \right. \right\}.$$

Lagrange对偶问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i = 1, \dots, m \\ & h_j(x) = 0, j = 1, \dots, l \\ & x \in D \end{aligned} \quad (1)$$

集约束

定义(1)的对偶问题:

$$\begin{aligned} \max \quad & \theta(w, v) \\ \text{s.t.} \quad & w \geq 0 \end{aligned} \quad (2)$$

其中 $\theta(w, v) = \inf \left\{ f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \mid x \in D \right\}$

若上式不存在有限下界时, 令 $\theta(w, v) = -\infty$.

$\theta(w, v)$ 称为Lagrange对偶函数。

Lagrange对偶问题

$$\max \theta(w, v)$$

$$s.t. \quad w \geq 0$$

$$\text{其中 } \theta(w, v) = \inf \left\{ f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \mid x \in D \right\}$$

$$L(x, w, v) = f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x)$$

Lagrange函数

对于任意的 $x \in D$, Lagrange函数 $L(x, w, v)$ 是 w, v 的线性函数, 于是对偶函数 $\theta(w, v)$ 作为线性函数的逐点下确界, 必然是一个凹函数, 所以, 对偶问题是一个凸规划问题。

例：考虑线性规划问题

$$\min cx$$

$$s.t. \quad A_1 x \geq b_1$$

$$A_2 x = b_2$$

$$x \geq 0$$

若取集合约束 $D = \{x | x \geq 0\}$ ，则该线性规划问题的Lagrange函数为

$$\theta(w, v) = \inf \{ cx - w^T (A_1 x - b_1) - v^T (A_2 x - b_2) \mid x \in D \}$$

$$= \inf \{ (c - w^T A_1 - v^T A_2)x + w^T b_1 + v^T b_2 \mid x \in D \}$$

$$= \begin{cases} w^T b_1 + v^T b_2 & \text{若 } c - w^T A_1 - v^T A_2 \geq 0 \\ -\infty & \text{若 } c - w^T A_1 - v^T A_2 \not\geq 0. \end{cases}$$

$$\max w^T b_1 + v^T b_2$$

$$s.t. \quad w^T A_1 + v^T A_2 \leq c$$

$$w \geq 0$$

线性规划的对偶问题为：

求下列非线性规划问题的对偶问题：

$$\begin{cases} \min & x_1^2 + x_2^2 \\ s.t. & x_1 + x_2 - 4 \geq 0 \\ & x_1, x_2 \geq 0 \end{cases}$$

解1: 把变量的非负限制作为集约束, 即

$$x \in D = \left\{ \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \mid x_1 \geq 0, x_2 \geq 0 \right\},$$

则 $\theta(w) = \inf \{x_1^2 + x_2^2 - w(x_1 + x_2 - 4) \mid x \in D\}.$



$$\begin{aligned}\theta(w) &= \inf \{x_1^2 + x_2^2 - w(x_1 + x_2 - 4) \mid x \in D\} \\ &= \inf \{x_1^2 - wx_1 + x_2^2 - wx_2 + 4w \mid x_1 \geq 0, x_2 \geq 0\} \\ &= \inf \{x_1^2 - wx_1 \mid x_1 \geq 0\} + \inf \{x_2^2 - wx_2 \mid x_2 \geq 0\} + 4w\end{aligned}$$

当 $w \geq 0$ 时,

$$\inf \{x_1^2 - wx_1 \mid x_1 \geq 0\} = \left(\frac{w}{2}\right)^2 - w \times \frac{w}{2} = -\frac{w^2}{4}.$$

$$\inf \{x_2^2 - wx_2 \mid x_2 \geq 0\} = \left(\frac{w}{2}\right)^2 - w \times \frac{w}{2} = -\frac{w^2}{4}.$$

$$\therefore \theta(w) = -\frac{w^2}{4} - \frac{w^2}{4} + 4w = -\frac{w^2}{2} + 4w.$$

对偶问题为:

$$\begin{cases} \max & -\frac{w^2}{2} + 4w \\ \text{s.t.} & w \geq 0 \end{cases}$$

对偶定理

$$\min f(x)$$

$$s.t. \quad g(x) \geq 0$$

$$h(x) = 0$$

$$x \in D$$

$$\max \theta(w, v)$$

$$s.t. \quad w \geq 0$$

$$g(x) = (g_1(x), \dots, g_m(x))^T$$

$$h(x) = (h_1(x), \dots, h_l(x))^T$$

$$\theta(w, v) = \inf \left\{ f(x) - w^T g(x) - v^T h(x) \mid x \in D \right\}$$

定理1(弱对偶定理)

设 x 和 (w, v) 分别是原问题和对偶问题的可行解, 则

$$f(x) \geq \theta(w, v).$$

推论1: 对于原问题和对偶问题, 必有

$$\inf \{f(x) \mid g(x) \geq 0, h(x) = 0, x \in D\} \geq \sup \{\theta(w, v) \mid w \geq 0\}.$$

推论2: 若 $f(\bar{x}) \leq \theta(\bar{w}, \bar{v})$, 其中 \bar{x} 为原问题的可行解, $\bar{w} \geq 0$, 则 \bar{x} 和 (\bar{w}, \bar{v}) 分别是原问题和对偶问题的最优解。

推论3: 若 $\inf \{f(x) \mid g(x) \geq 0, h(x) = 0, x \in D\} = -\infty$, 则对 $\forall w \geq 0$, 有 $\theta(w, v) = -\infty$ 。

推论4: 如果 $\sup \{\theta(w, v) \mid w \geq 0\} = +\infty$, 则原问题没有可行解。

对偶定理

$$\inf \{ f(x) \mid g(x) \geq 0, h(x) = 0, x \in D \} \stackrel{\text{记}}{=} f_{\min}$$

$$\sup \{ \theta(w, v) \mid w \geq 0 \} \stackrel{\text{记}}{=} \theta_{\max}$$

对偶间隙(dual gap):

$$\delta = f_{\min} - \theta_{\max} \geq 0$$

问题: $\delta = 0$ 成立的条件.

dual gap, 凸优化的时候等于0, 非凸优化也有可能等于0。

Lagrange乘子的意义

$$(NP) \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

设(NP)的局部最优解为 x^* ,相应的Lagrange乘子为 (w^*, v^*) , $w^* \geq 0$.

Lagrange乘子的意义

对约束的右端项进行扰动

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq \varepsilon_i \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = \lambda_j \quad j = 1, 2, \dots, l \end{cases}$$

扰动问题

令 $\varepsilon = (\varepsilon_1, \dots, \varepsilon_m)$, $\lambda = (\lambda_1, \dots, \lambda_l)$

设扰动问题的局部最优解为 $x^*(\varepsilon, \lambda)$, 相应的Lagrange乘子为 $(w^*(\varepsilon), v^*(\lambda))$, 则当 $(\varepsilon, \lambda) = (0, 0)$ 时, 有 $x^*(0, 0) = x^*$,

$(w^*(0), v^*(0)) = (w^*, v^*)$.

Lagrange乘子的意义

只有一个等式约束

$$(NP) \begin{cases} \min f(x) \\ s.t. \quad h(x) = 0 \end{cases}$$

设局部最优解为 x^* , 相应的乘子为 v^* .

$$\text{扰动问题} \begin{cases} \min f(x) \\ s.t. \quad h(x) = \lambda \end{cases}$$

设局部最优解为 $x^*(\lambda)$, 相应的乘子为 $v^*(\lambda)$.

$$\begin{aligned} \frac{d}{d\lambda} f(x^*(\lambda))|_{\lambda=0} &= \nabla_x f(x^*(\lambda))^T \frac{d}{d\lambda} x^*(\lambda)|_{\lambda=0} \\ &= \nabla_x f(x^*)^T \left[\frac{d}{d\lambda} x^*(\lambda) \right]_{\lambda=0}. \end{aligned}$$

Lagrange乘子的意义

由扰动问题的约束条件，得到

$$h(x^*(\lambda)) = \lambda$$

$$\therefore 1 = \frac{d}{d\lambda} h(x^*(\lambda))|_{\lambda=0} = \nabla_x h(x^*(\lambda))^T \frac{d}{d\lambda} x^*(\lambda)|_{\lambda=0}$$

$$= \nabla_x h(x^*)^T \left[\frac{d}{d\lambda} x^*(\lambda) \right]_{\lambda=0}.$$

由KKT条件 $\nabla f(x^*) - v^* \nabla h(x^*) = 0$

得 $\frac{d}{d\lambda} f(x^*(\lambda))|_{\lambda=0} = \nabla_x f(x^*)^T \left[\frac{d}{d\lambda} x^*(\lambda) \right]_{\lambda=0}$

$$= v^* \nabla_x h(x^*)^T \left[\frac{d}{d\lambda} x^*(\lambda) \right]_{\lambda=0} = v^*.$$

Lagrange乘子的意义

只有一个不等式约束 $(NP) \begin{cases} \min f(x) \\ s.t. \quad g(x) \geq 0 \end{cases}$

设局部最优解为 x^* , 相应的乘子为 w^* .

扰动问题 $\begin{cases} \min f(x) \\ s.t. \quad g(x) \geq \varepsilon \end{cases}$

设局部最优解为 $x^*(\varepsilon)$, 相应的乘子为 $w^*(\varepsilon)$.

并假设 $x^*(0) = x^*$, $w^*(0) = w^*$.

分两种情况讨论

Lagrange乘子的意义

(1) $g(x^*) = 0$, 即 $g(x) \geq 0$ 在 x^* 处是起作用约束.
当 $|\varepsilon|$ 很小时, 可以假设有 $g(x^*(\varepsilon)) = \varepsilon$

即 $g(x)$ 在 $x^*(\varepsilon)$ 处为起作用约束, 所以有

$$\left. \frac{d}{d\varepsilon} f(x^*(\varepsilon)) \right|_{\varepsilon=0} = w^*.$$

(2) $g(x^*) > 0$, 即 $g(x) \geq 0$ 在 x^* 处是不起作用约束.

此时, x^* 是无约束问题 $\min f(x)$ 的局部最优解,
因此当 $|\varepsilon|$ 很小时, x^* 也是扰动问题的局部最优解, 所以有

$$\left. \frac{d}{d\varepsilon} f(x^*(\varepsilon)) \right|_{\varepsilon=0} = 0 = w^*.$$

Lagrange乘子的意义

$$(NP) \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

定理：设 $f(x), g_i(x), h_j(x)$ 具有连续的二阶偏导数， x^* 是 (NP) 的局部最优解， (w^*, v^*) 是相应的Lagrange乘子向量。假设 $x^*(\lambda, \varepsilon)$ 是扰动问题的局部最优解， $(w^*(\lambda), v^*(\varepsilon))$ 是相应的乘子向量，则有

$$\nabla_{\lambda} f(x^*(\lambda))|_{\lambda=0} = w^*$$

$$\nabla_{\varepsilon} f(x^*(\varepsilon))|_{\varepsilon=0} = v^*.$$

$$z^* = \sum_{j=1}^n c_j x_j = \sum_{i=1}^m b_i y_i$$

影子价格

- **定义：** 在一对 P 和 D 中，若 P 的某个约束条件的右端项常数 b_i （第 i 种资源的拥有量）增加一个单位时，所引起目标函数最优值 z^* 的改变量称为第 i 种资源的**影子价格**，其值等于 D 问题中对偶变量 y_i^* 。

- **1. 影子价格的数学分析：**

$$P: \max z = c^T x \quad D: \min w = y^T b$$

$$\begin{cases} Ax \leq b \\ x \geq 0 \end{cases} \quad \begin{cases} A^T y \geq c \\ y \geq 0 \end{cases}$$

- **由对偶问题的基本性质可得：** $z^* = \sum_{j=1}^n c_j x_j = \sum_{i=1}^m b_i y_i$

影子价格

- 2. 影子价格的经济意义

- 1) 影子价格是一种边际价格

$$z^* = \sum_{j=1}^n c_j x_j = \sum_{i=1}^m b_i y_i$$

- 在其它条件不变的情况下，单位资源数量的变化所引起的目标函数最优值的变化。即对偶变量 y_i 就是第 i 种资源的影子价格。即：

$$\frac{\partial Z^*}{\partial b_i} = y_i^* (i = 1, 2 \cdots m)$$

Lagrange乘子的意义

定义广义的**Lagrange**函数:

$$\begin{aligned} L(x, w, v) &= f(x) - \sum_{i=1}^m w_i g_i(x) - \sum_{j=1}^l v_j h_j(x) \\ &= f(x) - w^T g(x) - v^T h(x) \end{aligned}$$

其中 $w = (w_1, w_2, \dots, w_m)^T$

$v = (v_1, v_2, \dots, v_l)^T$

$g(x) = (g_1(x), \dots, g_m(x))^T$

$h(x) = (h_1(x), \dots, h_l(x))^T$.



乘子向量

Lagrange乘子的意义

例：某企业预算以2千元作为广告费，根据以往的经验，若以 x_1 千元作广播广告， x_2 千元作报纸广告，销售金额为

$$-2x_1^2 - 10x_2^2 - 8x_1x_2 + 18x_1 + 34x_2 \text{ (千元)}$$

试问：

- (1) 如何分配2千元广告费？
- (2) 广告费预算作微小改变的影响如何？

Lagrange乘子的意义

解：最优化问题为

$$\min 2x_1^2 + 10x_2^2 + 8x_1x_2 - 18x_1 - 34x_2$$

$$s.t. \quad x_1 + x_2 - 2 = 0, \quad x_1 \geq 0, x_2 \geq 0$$

相应的KKT条件为

$$\begin{cases} 4x_1 + 8x_2 - 18 - w_1 - v = 0 \\ 20x_2 + 8x_1 - 34 - w_2 - v = 0 \\ w_1x_1 = 0, \quad w_2x_2 = 0 \\ x_1 + x_2 - 2 = 0 \\ x_1, x_2, w_1, w_2 \geq 0 \end{cases}$$



KKT点为 $x^* = (1, 1)^T$

$$w_1^* = w_2^* = 0$$

$$v = -6$$

Lagrange乘子的意义

广告费作微小改动，考虑扰动问题

$$\min f(x) = 2x_1^2 + 10x_2^2 + 8x_1x_2 - 18x_1 - 34x_2$$

$$s.t. \quad x_1 + x_2 - 2 = \varepsilon$$

$$x_1 \geq 0, x_2 \geq 0$$

$$\text{有 } \frac{df(x^*(\varepsilon))}{d\varepsilon} \Big|_{\varepsilon=0} = \nu^* = -6$$

当 ε 增加时， $f(x^*(\varepsilon))$ 下降，即 $-f(x^*(\varepsilon))$ 上升，
即当广告费增加后，销售金额也随着增加，而且
销售金额的增加大约是广告费的6倍，可见适当
增加广告费的预算是有利的。

罚函数法

借助罚函数把约束优化问题转化为无约束优化问题，进而用无约束最优化方法进行求解。

罚函数法 { 外点罚函数法
内点罚函数法
乘子罚函数法

Sequential unconstrained minimization
technique 序列无约束最小化技术

外点罚函数法

外点罚函数法：通过对不可行的迭代点施加惩罚，并随着迭代过程中对不可行性增大惩罚，迫使迭代点逐步向可行域靠近。一旦迭代点成为可行点。则这个迭代点就是原问题的最优解。

$$(A) \quad \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

其中 $f(x)$, $g_i(x)$ ($i = 1, 2, \dots, m$), $h_j(x)$ ($j = 1, 2, \dots, l$) 在 E^n 上连续。

$$S = \{x \mid g_i(x) \geq 0 (i = 1, 2, \dots, m), h_j(x) = 0 (j = 1, 2, \dots, l)\}$$

外点罚函数法

引入罚项

$$p(x) = \sum_{i=1}^m \varphi[g_i(x)] + \sum_{j=1}^l \psi[h_j(x)]$$

其中 $\varphi(y), \psi(y)$ 是连续函数, 且满足

$$\begin{cases} \varphi(y) = 0 & \text{当 } y \geq 0 \\ \varphi(y) > 0 & \text{当 } y < 0 \end{cases}$$

$$\begin{cases} \psi(y) = 0 & \text{当 } y = 0 \\ \psi(y) > 0 & \text{当 } y \neq 0 \end{cases}$$

函数 φ 和 ψ 的典型取法:

$$\varphi[g_i(x)] = [\max\{0, -g_i(x)\}]^\alpha \quad \psi[h_j(x)] = |h_j(x)|^\beta$$

其中 $\alpha \geq 1, \beta \geq 1$ 均为给定常数, 通常取 $\alpha = \beta = 2$ 。

外点罚函数法

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$



$$\min F(x, \sigma) = f(x) + \sigma p(x)$$


$$\min F(x, \sigma) = f(x) + \sigma \left[\sum_{i=1}^m \varphi[g_i(x)] + \sum_{j=1}^l \psi[h_j(x)] \right]$$

其中 σ 是很大的正数。 $\bar{x}_\sigma \rightarrow x^*$ (当 $\sigma \rightarrow +\infty$)

外点罚函数法

$$\min f(x) = (x_1 - 1)^2 + x_2^2$$

$$s.t. \quad g(x) = x_2 - 1 \geq 0$$



解：定义罚函数

$$\begin{aligned} F(x, \sigma) &= (x_1 - 1)^2 + x_2^2 + \sigma [\max \{0, -(x_2 - 1)\}]^2 \\ &= \begin{cases} (x_1 - 1)^2 + x_2^2 & x_2 \geq 1 \\ (x_1 - 1)^2 + x_2^2 + \sigma (x_2 - 1)^2 & x_2 < 1 \end{cases} \end{aligned}$$

外点罚函数法

$$\frac{\partial F}{\partial x_1} = 2(x_1 - 1) \quad \frac{\partial F}{\partial x_2} = \begin{cases} 2x_2 & x_2 \geq 1 \\ 2x_2 + 2\sigma(x_2 - 1) & x_2 < 1 \end{cases}$$

$$\text{令 } \frac{\partial F}{\partial x_1} = 0 \quad \frac{\partial F}{\partial x_2} = 0 \quad \text{得}$$

$$\bar{x}_\sigma = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ \frac{\sigma}{1+\sigma} \end{pmatrix} \rightarrow \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad (\sigma \rightarrow +\infty)$$

外点罚函数法

$$\min x_1 + x_2$$

$$s.t. \quad x_1 - x_2^2 = 0$$

定义罚函数: $F(x, \sigma) = x_1 + x_2 + \sigma(x_1 - x_2^2)^2$

$$\nabla F(x, \sigma) = \begin{pmatrix} 1 + 2\sigma(x_1 - x_2^2) \\ 1 + 2\sigma(x_1 - x_2^2)(-2x_2) \end{pmatrix}$$

令 $\nabla F(x, \sigma) = 0$, 得

$$\bar{x}_\sigma = \left(\frac{1}{4} - \frac{1}{\sigma}, -\frac{1}{2} \right)^T \rightarrow \left(\frac{1}{4}, -\frac{1}{2} \right)^T \quad (\sigma \rightarrow \infty)$$

外点罚函数法



$$\min f(x) = x_1 + x_2$$

$$s.t. \quad g_1(x) = -x_1^2 + x_2 \geq 0$$

$$g_2(x) = x_1 \geq 0$$

解：定义罚函数

$$F(x, \sigma) = x_1 + x_2 + \sigma [\max \{0, x_1^2 - x_2\}]^2 + \sigma [\max \{0, -x_1\}]^2$$

$$\frac{\partial F}{\partial x_1} = 1 + 2\sigma [2 \max \{0, x_1^2 - x_2\} x_1 + \max \{0, -x_1\} (-1)]$$

$$\frac{\partial F}{\partial x_2} = 1 + 2\sigma \max \{0, x_1^2 - x_2\} (-1)$$

外点罚函数法

$$\text{令 } \frac{\partial F}{\partial x_1} = 0 \quad \frac{\partial F}{\partial x_2} = 0 \quad \text{得}$$

$$\begin{cases} 1 + 4\sigma x_1(x_1^2 - x_2) + 2\sigma x_1 = 0 \\ 1 - 2\sigma(x_1^2 - x_2) = 0 \end{cases}$$

$$\Rightarrow x_1 = -\frac{1}{2 + 2\sigma} \quad x_2 = \frac{1}{(2 + 2\sigma)^2} - \frac{1}{2\sigma}$$

$$\text{当 } \sigma \rightarrow +\infty \text{ 时, 有 } \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \rightarrow \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

外点罚函数法

步骤:

1. 给定初始点 $x^{(0)}$, 初始罚因子 $\sigma_1 > 0 (\sigma_1 = 1)$, 放大系数 $c > 1$, 允许误差 $\varepsilon > 0$, 置 $k = 1$ 。

2. 以 $x^{(k-1)}$ 为初始点, 求解无约束问题

$$\min f(x) + \sigma_k p(x)$$

设其极小点为 $x^{(k)}$ 。

3. 若 $\sigma_k p(x^{(k)}) < \varepsilon$, 则停止计算, 得到点 $x^{(k)}$; 否则,

令 $\sigma_{k+1} = c\sigma_k$, 置 $k := k + 1$, 返回2。

外点罚函数法

例：用外点法求解

$$\begin{aligned} \min & (x-1)^2 \\ \text{s.t.} & x-2 \geq 0 \end{aligned}$$

解：取 $x^{(0)} = 0$, $\sigma_1 = 1$, 令

$$p(x) = [\max\{0, -x + 2\}]^2 \quad \text{则}$$

$$p(x) = \begin{cases} 0 & x \geq 2 \\ (-x + 2)^2 & x < 2 \end{cases}$$

外点罚函数法

第一次迭代


求解无约束最优化问题:

$$\min F(x, \sigma_1) = (x-1)^2 + 1 \times p(x)$$

$$\text{其中 } F(x, \sigma_1) = \begin{cases} (x-1)^2 & x \geq 2 \\ (x-1)^2 + 1 \times (-x+2)^2 & x < 2 \end{cases}$$

$$\text{解得: } x^{(1)} = \frac{3}{2}$$

$$\text{令 } \sigma_2 = 10 \times \sigma_1 = 10$$



外点罚函数法

第二次迭代


求解无约束最优化问题：

$$\min F(x, \sigma_1) = (x-1)^2 + 10 \times p(x)$$

$$\text{其中 } F(x, \sigma_1) = \begin{cases} (x-1)^2 & x \geq 2 \\ (x-1)^2 + 10 \times (-x+2)^2 & x < 2 \end{cases}$$

$$\text{解得： } x^{(1)} = \frac{21}{11}$$

$$\text{令 } \sigma_3 = 10 \times \sigma_2 = 100$$



外点罚函数法

第三次迭代

求解无约束最优化问题:

$$\min F(x, \sigma_1) = (x-1)^2 + 100 \times p(x)$$

$$\text{其中 } F(x, \sigma_1) = \begin{cases} (x-1)^2 & x \geq 2 \\ (x-1)^2 + 100 \times (-x+2)^2 & x < 2 \end{cases}$$

$$\text{解得: } x^{(2)} = \frac{201}{101}$$

以此类推, 得序列:

$$\frac{3}{2}, \frac{21}{11}, \frac{201}{101}, \frac{2001}{1001}, \dots \quad x^* = 2$$

外点罚函数法

引理1 对于由外点法所产生的序列 $\{x^{(k)}\}$, 总有

$$(1) F(x^{(k+1)}, \sigma_{k+1}) \geq F(x^{(k)}, \sigma_k)$$

$$(2) p(x^{(k+1)}) \leq p(x^{(k)})$$

$$(3) f(x^{(k+1)}) \geq f(x^{(k)})$$

证明:(1)由 $F(x, \sigma) = f(x) + \sigma p(x)$ 和 $\sigma_{k+1} > \sigma_k$ 知

$$\begin{aligned} F(x^{(k+1)}, \sigma_{k+1}) &= f(x^{(k+1)}) + \sigma_{k+1} p(x^{(k+1)}) \\ &\geq f(x^{(k+1)}) + \sigma_k p(x^{(k+1)}) = F(x^{(k+1)}, \sigma_k) \end{aligned}$$

$\because x^{(k)}$ 是 $F(x, \sigma_k)$ 的极小点, \therefore 对 $\forall x$,有 $F(x, \sigma_k) \geq F(x^{(k)}, \sigma_k)$

$$\Rightarrow F(x^{(k+1)}, \sigma_k) \geq F(x^{(k)}, \sigma_k)$$

$$\Rightarrow F(x^{(k+1)}, \sigma_{k+1}) \geq F(x^{(k)}, \sigma_k)$$

外点罚函数法

(2) $x^{(k)}$ 和 $x^{(k+1)}$ 分别使 $F(x, \sigma_k), F(x, \sigma_{k+1})$ 取极小

$$\therefore f(x^{(k+1)}) + \sigma_k p(x^{(k+1)}) \geq f(x^{(k)}) + \sigma_k p(x^{(k)}) \quad (*)$$

$$f(x^{(k)}) + \sigma_{k+1} p(x^{(k)}) \geq f(x^{(k+1)}) + \sigma_{k+1} p(x^{(k+1)})$$

$$\sigma_k p(x^{(k+1)}) + \sigma_{k+1} p(x^{(k)}) \geq \sigma_k p(x^{(k)}) + \sigma_{k+1} p(x^{(k+1)})$$

$$\Rightarrow (\sigma_{k+1} - \sigma_k) p(x^{(k)}) \geq (\sigma_{k+1} - \sigma_k) p(x^{(k+1)})$$

$$\Rightarrow p(x^{(k)}) \geq p(x^{(k+1)})$$

(3) 由(*), 得

$$f(x^{(k+1)}) - f(x^{(k)}) \geq \sigma_k (p(x^{(k)}) - p(x^{(k+1)}))$$

$$\geq 0$$

$$(2) p(x^{(k+1)}) \leq p(x^{(k)})$$

$$(3) f(x^{(k+1)}) \geq f(x^{(k)})$$

外点罚函数法

引理2 设 x^* 是问题(A)的一个最优解,则对 $\forall k$,有

$$f(x^*) \geq F(x^{(k)}, \sigma_k) \geq f(x^{(k)}).$$

证明:因为 x^* 是问题(A)的最优解,所以有

$$p(x^*) = 0$$

$\because x^{(k)}$ 是 $F(x, \sigma_k)$ 的极小点

$$\therefore f(x^*) = F(x^*, \sigma_k) \geq F(x^{(k)}, \sigma_k)$$

$$\text{又} \because \sigma_k p(x^{(k)}) \geq 0$$

$$\therefore F(x^{(k)}, \sigma_k) = f(x^{(k)}) + \sigma_k p(x^{(k)}) \geq f(x^{(k)})$$

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \\ \quad \quad h_j(x) = 0 \end{cases}$$

外点罚函数法

外点罚函数法的一个重要特点:

函数 $F(x, \sigma)$ 是在整个空间 E^n 内进行优化, 初始点可任意选择, 且外点法也可用于非凸规划的最优化

缺点:

1. 惩罚项 $op(x)$ 的二阶偏导数一般不存在;
2. 外点法的中间结果不是可行解, 不能作为近似解;
3. 当点 $x^{(k)}$ 接近最优解时, 罚因子 σ_k 很大. 可能使罚函数性质变坏, 使搜索产生极大困难

外点罚函数法

$$\begin{array}{ll} \min & x_1^2 + x_2^2 \\ \text{s.t.} & x_1 + 1 = 0 \end{array}$$

其罚函数为

$$F(x, \sigma) = x_1^2 + x_2^2 + \sigma(x_1 + 1)^2.$$

*Hessian*矩阵为

$$\nabla_x^2 F(x, \sigma) = \begin{pmatrix} 2 + \sigma & 0 \\ 0 & 2 \end{pmatrix}$$

$$\text{条件数} = \frac{\text{最大特征值}}{\text{最小特征值}} = \frac{2 + \sigma}{2} \rightarrow \infty (\sigma \rightarrow \infty)$$

外点罚函数法

$$\begin{cases} \min -x^4 \\ s.t. \quad x = 0 \end{cases} \quad x^* = 0$$

若取 $p(x) = x^2$, 则 $F(x, \sigma) = -x^4 + \sigma x^2$, 没有最小点.

若取 $p(x) = x^8$, 则 $F(x, \sigma) = -x^4 + \sigma x^8$, 有极小点

$$x_\sigma = \left(\frac{1}{2\sigma} \right)^{\frac{1}{4}} \rightarrow 0$$

内点罚函数法

基本思想：迭代总是从内点出发,并保持在可行域内部进行搜索。

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \end{cases}$$

其中 $f(x)$, $g_i(x)(i = 1, 2, \dots, m)$ 是连续函数。

$$S = \{x \mid g_i(x) \geq 0, i = 1, 2, \dots, m, x \in E^n\}$$

$$\text{int } S = \{x \mid g_i(x) > 0, i = 1, 2, \dots, m, x \in E^n\}$$

内点罚函数法

障碍因子

障碍函数 $G(x, r) = f(x) + rB(x)$

其中 r 是很小的正数， $B(x)$ 定义在可行域内部，它满足两个条件：

- (1) $B(x)$ 是连续函数；
- (2) 当点 x 趋向可行域边界时， $B(x) \rightarrow +\infty$ 。

两种最重要的形式：

倒数障碍函数

对数障碍函数

$$B(x) = \sum_{i=1}^m \frac{1}{g_i(x)} \quad B(x) = -\sum_{i=1}^m \ln g_i(x)$$

内点罚函数法

两种障碍函数的比较 $\min -x$

$$s.t. \quad -x - 1 \geq 0$$

取 $B(x) = \frac{1}{-x-1}$, 则内罚函数为

$$G(x, r) = -x - \frac{r}{x+1}$$

$$\text{令 } \frac{\partial G}{\partial x} = -1 + \frac{r}{(x+1)^2} = 0$$

$$\text{得到 } \bar{x} = \bar{x}(r) = -1 - \sqrt{r}$$

当 $r \rightarrow 0$ 时, 有 $\bar{x}(r) \rightarrow -1 = x^*$.

内点罚函数法

两种障碍函数的比较

$$\min -x$$

$$s.t. \quad -x - 1 \geq 0$$

取 $B(x) = -\ln(-x-1)$, 则内罚函数为

$$G(x, r) = -x - r \ln(-x-1)$$

$$\text{令 } \frac{\partial G}{\partial x} = -1 - \frac{r}{x+1} = 0$$

$$\text{得到 } \bar{x} = \bar{x}(r) = -1 - r$$

当 $r \rightarrow 0$ 时, 有 $\bar{x}(r) \rightarrow -1 = x^*$.

内点罚函数法

例: 考虑约束优化问题

$$\min \frac{x}{2}$$
$$s.t. \quad x \geq 1$$

该问题的对数障碍函数为

$$G(x, r) = \frac{x}{2} - r \ln(x-1)$$

$G(x, r)$ 的最小点为:

$$x_r = 1 + 2r \rightarrow 1 (r \rightarrow 0)$$

$$G(x_r, r) = \frac{1}{2} + r - r \ln 2r \rightarrow \frac{1}{2} (r \rightarrow 0)$$

内点罚函数法

$$\begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \end{cases}$$



$$\begin{cases} \min G(x, r) = f(x) + rB(x) \\ s.t. \quad x \in \text{int } S \end{cases}$$

$$\begin{cases} \min G(x, r_k) = f(x) + r_k B(x) \\ s.t. \quad x \in \text{int } S \end{cases}$$

其中 $\{r_k\}$ 为严格单调减且趋于0的障碍因子数列。

内点罚函数法

步骤:

1. 给定初始点 $x^{(0)} \in \text{int } S$, 允许误差 $\varepsilon > 0$, 初始参数 r_1 , 缩小系数 $\beta \in (0, 1)$, 置 $k = 1$ 。

2. 以 $x^{(k-1)}$ 为初始点, 求解下列问题

$$\min f(x) + r_k B(x)$$

$$s.t. \quad x \in \text{int } S$$

设其极小点为 $x^{(k)}$ 。

3. 若 $r_k B(x^{(k)}) < \varepsilon$, 则停止计算, 得到点 $x^{(k)}$; 否则,

令 $r_{k+1} = \beta r_k$, 置 $k := k + 1$, 返回2。

内点罚函数法

例:用内点罚函数法求解下列问题

$$\min x_1 + x_2$$

$$s.t. \quad -x_1^2 + x_2 \geq 0$$

$$x_1 \geq 0$$

解: 定义障碍函数

$$G(x, r) = x_1 + x_2 - r_k \ln(-x_1^2 + x_2) - r_k \ln x_1$$

$$\text{令 } \frac{\partial G}{\partial x_1} = 1 - \frac{-2x_1 r_k}{-x_1^2 + x_2} - \frac{r_k}{x_1} = 0, \quad \frac{\partial G}{\partial x_2} = 1 - \frac{r_k}{-x_1^2 + x_2} = 0$$


$$\Rightarrow x_1 = \frac{1}{4}(-1 + \sqrt{1 + 8r_k}), \quad x_2 = \frac{3r_k}{2} - \frac{1}{8}(-1 + \sqrt{1 + 8r_k})$$

1/7/2025 当 $r_k \rightarrow 0$ 时, $x^* = (0, 0)^T$

内点罚函数法

$$x_1 = \frac{1}{4} \left(-1 + \sqrt{1 + 8r_k} \right), \quad x_2 = \frac{3r}{2} - \frac{1}{8} \left(-1 + \sqrt{1 + 8r_k} \right)$$

	r_k	$x_1(r_k)$	$x_2(r_k)$
1	1	0.5	1.25
2	0.5	0.309	0.595
3	0.25	0.183	0.283
4	0.1	0.085	0.107
5	0.0001	0	0



内点罚函数法

求初始内点的迭代步骤

1. 任取 $x^{(0)} \in E^n, r_0 > 0$ (如取 $r_0 = 1$), 置 $k := 0$ 。
2. 令 $S_k = \{i \mid g_i(x^{(k)}) \leq 0, 1 \leq i \leq m\}$,
 $T_k = \{i \mid g_i(x^{(k)}) > 0, 1 \leq i \leq m\}$ 。
3. 若 $S_k = \emptyset$, 停止计算; 否则, 转 4。
4. 构造函数

$$\tilde{P}(x, r_k) = -\sum_{i \in S_k} g_i(x) + r_k \sum_{i \in T_k} \frac{1}{g_i(x)} \quad (r_k > 0)$$

记 $\tilde{R}_k = \{x \mid g_i(x) > 0 \quad i \in T_k\}$

内点罚函数法

5. 以 $x^{(k)}$ 为初始点, 在 \tilde{R}_k 域内, 求障碍函数 $\tilde{P}(x, r_k)$ 的极小点:

$$\min \tilde{P}(x, r_k)$$

$$s.t. \quad x \in \tilde{R}_k$$

得 $x^{(k+1)}$, 转6。

6. 令 $0 < r_{k+1} < r_k$ (如取 $r_{k+1} = \frac{1}{10} r_k$), 置 $k := k + 1$,

转2。

内点罚函数法

内点罚函数法优点

迭代总在可行域内进行，每一个中间结果都是可行解，可以作为近似解。

内点罚函数法缺点

选取初始可行点较困难，且只适用于含不等式约束的非线性规划问题。

混合罚函数法

$$(A) \quad \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0 \quad i = 1, 2, \dots, m \\ \quad \quad h_j(x) = 0 \quad j = 1, 2, \dots, l \end{cases}$$

引入增广目标函数

$$P(x, r) = f(x) - r \sum_{i \in I_1} \ln g_i(x) \\ + \frac{1}{r} \left[\sum_{i \in I_2} (\min(0, -g_i(x)))^2 + \sum_{j=1}^l h_j(x)^2 \right]$$

其中 $I_1 = \{i \mid g_i(x) > 0, i = 1, \dots, m\}$, $I_2 = \{i \mid g_i(x) \leq 0, i = 1, \dots, m\}$

拉格朗日乘子法

考虑等式约束优化问题

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, \quad i = 1, \dots, m. \end{aligned} \tag{6.1}$$

其中 $f(x)$ 和 $c_i(x)$ 连续可微的, $m < n$ 。

设 x^* 是局部极小点且是正则点, 那么由KKT条件, 存在乘子向量 $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)^T$, 使得

$$\nabla f(x^*) - \sum_{i=1}^m \lambda_i^* \nabla c_i(x^*) = 0, \tag{6.2}$$

$$c_i(x^*) = 0, \quad i = 1, \dots, m. \tag{6.3}$$

拉格朗日乘子法

算法 6.1

步 1. 构造拉格朗日函数

$$L(x, \lambda) = f(x) - \sum_{i=1}^m \lambda_i c_i(x).$$

步 2. 解 *KKT* 条件方程组 (6.2)-(6.3) 得到 (x^*, λ^*) .

拉格朗日乘子法

例:

$$\min f(x) = (x_1 - \frac{13}{3})^2 + (x_2 - \frac{1}{2})^2 - x_3 \quad (6.4)$$

$$\text{s.t. } c_1(x) = x_1 + \frac{5}{3}x_2 - 10 = 0, \quad (6.5)$$

$$c_2(x) = (x_2 - 2)^2 + x_3 - 4 = 0. \quad (6.6)$$

解 1. 求约束梯度

$$\nabla c_1(x) = \begin{bmatrix} 1 \\ \frac{5}{3} \\ 0 \end{bmatrix}, \quad \nabla c_2(x) = \begin{bmatrix} 0 \\ 2x_2 - 4 \\ 1 \end{bmatrix}.$$

2. 构造拉格朗日函数

$$\begin{aligned} L(x, \lambda) = & (x_1 - \frac{13}{3})^2 + (x_2 - \frac{1}{2})^2 - x_3 \\ & - \lambda_1(x_1 + \frac{5}{3}x_2 - 10) - \lambda_2((x_2 - 2)^2 + x_3 - 4). \end{aligned}$$

拉格朗日乘子法

3. 解KKT条件方程组:

$$\frac{\partial L}{\partial x_1} = 2(x_1 - \frac{13}{3}) - \lambda_1 = 0,$$

$$\frac{\partial L}{\partial x_2} = 2(x_2 - \frac{1}{2}) - \frac{5}{3}\lambda_1 - 2\lambda_2(x_2 - 2) = 0,$$

$$\frac{\partial L}{\partial x_3} = -1 - \lambda_2 = 0,$$

$$\frac{\partial L}{\partial \lambda_1} = -(x_1 + \frac{5}{3}x_2 - 10) = 0,$$

$$\frac{\partial L}{\partial \lambda_2} = -((x_2 - 2)^2 + x_3 - 4) = 0.$$

解得

$$x^* = \begin{pmatrix} 8\frac{11}{18} \\ \frac{5}{6} \\ 2\frac{23}{36} \end{pmatrix}, \lambda^* = \begin{pmatrix} \frac{77}{9} \\ -1 \end{pmatrix}. \quad \square$$

增广拉格朗日乘子法

罚函数法的主要缺点是要求罚参数 $\sigma \rightarrow +\infty$ 时, 才能得到约束优化问题的解。在罚函数的基础上提出的增广Lagrange乘子法(又称乘子罚函数法)可以克服这个缺点。

考虑等式约束优化问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & c_i(x) = 0, i \in \{1, 2, \dots, m\}. \end{aligned} \quad (11.1)$$

增广拉格朗日函数为

$$P(x, \lambda, \sigma) = f(x) - \sum_{i=1}^m \lambda_i c_i(x) + \frac{1}{2} \sum_{i=1}^m \sigma_i c_i^2(x), \quad (11.2)$$

这里 λ_i 为乘子, σ_i 为罚因子。显然, 增广拉格朗日函数是由拉格朗日函数再加上一个惩罚项 $\frac{1}{2} \sum_{i=1}^m \sigma_i c_i^2(x)$ 构成的。

增广拉格朗日乘子法

给定 $\lambda^{(k)}$, $\sigma^{(k)}$, 令 x_{k+1} 为无约束优化问题

$$\min_x P(x, \lambda^{(k)}, \sigma^{(k)}) \quad (11.3)$$

的解。于是，我们立即有

$$\begin{aligned} & \nabla_x P(x_{k+1}, \lambda^{(k)}, \sigma^{(k)}) \\ = & \nabla f(x_{k+1}) - \sum_{i=1}^m \lambda_i^{(k)} \nabla c_i(x_{k+1}) + \sum_{i=1}^m \sigma_i^{(k)} c_i(x_{k+1}) \nabla c_i(x_{k+1}) \\ = & \nabla f(x_{k+1}) - \sum_{i=1}^m [\lambda_i^{(k)} - \sigma_i^{(k)} c_i(x_{k+1})] \nabla c_i(x_{k+1}) \\ = & 0. \end{aligned} \quad (11.4)$$

与在 x^* 处的一阶必要条件相比，我们取

$$\lambda_i^{(k+1)} = \lambda_i^{(k)} - \sigma_i^{(k)} c_i(x_{k+1}), \quad i = 1, \dots, m \quad (11.5)$$

做为下一次迭代的Lagrange乘子。

增广拉格朗日乘子法

这样，我们有

$$\nabla f(x_{k+1}) - \sum_{i=1}^m \lambda_i^{(k+1)} \nabla c_i(x_{k+1}) = 0.$$

在算法中，当

$$|c_i(x_{k+1})| \leq \frac{1}{4} |c_i(x_k)| \quad (11.6)$$

不满足时，我们就扩大相应的罚因子，令

$$\sigma_i^{(k+1)} = 10\sigma_i^{(k)}.$$

11.6式说明：迭代点的极限满足等式约束，在迭代过程中，等式约束是不满足的。但是还是希望约束满足，所以当约束的满足情况没有变好时，就会增大惩罚因子。

增广拉格朗日乘子法

- 步 1. 给出初始点 $x_1 \in R^n$, $\lambda^{(1)} \in R^m$, $\sigma_i^{(1)} > 0, i = 1, \dots, m$, $\varepsilon \geq 0$, $k := 1$.
- 步 2. 求解(11.3)得到 x_{k+1} . 如果 $\|c(x_{k+1})\|_\infty \leq \varepsilon$, 则停。
- 步 3. 对 $i = 1, \dots, m$, 令

$$\sigma_i^{(k+1)} = \begin{cases} \sigma_i^{(k)}, & \text{如果(11.6)成立;} \\ \max(10\sigma_i^{(k)}, k^2), & \text{否则.} \end{cases}$$

- 步 4. 由(11.5)计算乘子 $\lambda_i^{(k+1)}$, $i = 1, \dots, m$. $k := k + 1$; 转步2.



谢谢!

